

$$\Sigma = \begin{bmatrix} \text{Var}(x) & \text{Cov}(x, y) \\ \text{Cov}(x, y) & \text{Var}(y) \end{bmatrix}$$

$$\text{Var}(x) = \frac{1}{n} \sum (x_i - \bar{x})^2$$

$$\text{Cov}(x, y) = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

(1)

Class A :

$$\bar{x}_A = \frac{-2 - 1 + 0 + 3 + 2 + 0 + 1}{7} = \frac{13}{7}$$

$$\bar{y}_A = \frac{0 + 1 + 1 + 2 + 2 + 3 + 0}{7} = \frac{15}{7}$$

$$\rightarrow \bar{A} = \begin{bmatrix} \frac{13}{7} \\ \frac{15}{7} \end{bmatrix}$$

$$\text{Var}(x) = \frac{1}{7} \sum (x_i - \frac{13}{7})^2 = 0.1844$$

$$\text{Var}(y) = \frac{1}{7} \sum (y_i - \frac{15}{7})^2 = 0.1844$$

$$\text{Cov}(x, y) = \frac{1}{7} \sum (x_i - \frac{13}{7})(y_i - \frac{15}{7}) = 0.1844$$

$$\rightarrow \Sigma_A = \begin{bmatrix} 0.1844 & 0.1844 \\ 0.1844 & 0.1844 \end{bmatrix}$$

Class B :

$$\bar{x}_B = \frac{(0 - 2 - 0 - 2)}{4} = -\frac{1}{2}$$

$$\bar{y}_B = \frac{-2 - 2 - 1 + 1}{4} = -\frac{1}{2}$$

$$\rightarrow \bar{B} = \begin{bmatrix} -\frac{1}{2} \\ -\frac{1}{2} \end{bmatrix}$$

$$\text{Var}(x) = \frac{1}{4} \sum (x_i + \frac{1}{2})^2 = 0.5$$

$$\text{Var}(y) = \frac{1}{4} \sum (y_i + \frac{1}{2})^2 = 0.5$$

$$\text{Cov}(x, y) = \frac{1}{4} \sum (x_i + \frac{1}{2})(y_i + \frac{1}{2}) = -0.5$$

$$\rightarrow \Sigma_B = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix}$$

$$g_A(x) = -\frac{d}{2} \ln 2\pi - \frac{d}{2} \ln |\Sigma_A| - \frac{1}{2} (x - \bar{A})^T \Sigma_A^{-1} (x - \bar{A}) + \ln(P(A))$$

$$g_A(x) = -\ln 0.1844 + \ln \frac{1}{7} - \frac{1}{2} \begin{bmatrix} x - \frac{13}{7} & y - \frac{15}{7} \end{bmatrix} \begin{bmatrix} 0.1844 & -0.1844 \\ -0.1844 & 0.1844 \end{bmatrix} \begin{bmatrix} x - \frac{13}{7} \\ y - \frac{15}{7} \end{bmatrix}$$

$$g_A(x) = -0.1844 - \frac{1}{2} (0.1844x^2 - 0.1844xy - 0.1844xy + 0.1844y^2 - 0.1844x - 0.1844y)$$


$$g_B(x) = -\ln 0.5 + \ln \frac{1}{4} - \frac{1}{2} \begin{bmatrix} x + \frac{1}{2} & y + \frac{1}{2} \end{bmatrix} \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} \begin{bmatrix} x + \frac{1}{2} \\ y + \frac{1}{2} \end{bmatrix}$$

$$g_B(x) = -0.5 - \frac{1}{2} [0.5x^2 - 0.5xy + 0.5xy - 0.5y^2 + 0.5x + 0.5y]$$

(1)

$$g_A(x) = g_B(x)$$

$$1000x^2 + 111y x + 111220 x + 01239 y^2 + 410422 y + 10117 = 0$$



به فوبی جدا کرده است!

D

$$P(w_1) = P(w_2) = \frac{1}{2} \quad P(x|w_i) = \frac{1}{\pi b} \frac{1}{1 + (\frac{x-a_i}{b})^2} \quad i=1,2 \quad (2)$$

$$P(\text{error}) = P(w_1) - \int [P(w_1) P(x|w_1) - P(w_2) P(x|w_2)] dx \quad (\text{الف})$$

برای پیدا کردن حداقل احتمال خطا از $P(\text{error})$ نسبت به x مشتق می‌گیریم

$$\frac{dP(\text{error})}{dx} = -[P(w_1) P(x|w_1) - P(w_2) P(x|w_2)] = 0$$

→

$$P(w_1) P(x|w_1) = P(w_2) P(x|w_2)$$

$$\frac{1}{2} \frac{1}{\pi b} \frac{1}{1 + (\frac{x-a_1}{b})^2} = \frac{1}{2} \frac{1}{\pi b} \frac{1}{1 + (\frac{x-a_2}{b})^2}$$

$$\Rightarrow \left(\frac{x-a_1}{b}\right)^2 = \left(\frac{x-a_2}{b}\right)^2$$

وقتی $a_1 = a_2$ یعنی احتمال هر دو کلاس در هر نقطه با هم برابر است، یعنی خطای ما به Max حالت فروزش $\rightarrow \infty$ می‌رسد

$$(1) \quad \frac{x-a_1}{b} = \frac{x-a_2}{b} \Rightarrow \boxed{a_1 = a_2}$$

$$(2) \quad \frac{x-a_1}{b} = \frac{a_2-x}{b} \Rightarrow \boxed{x = \frac{a_1+a_2}{2}}$$

در این حالت خطای ما Min

(2)

حال جابجایی می کنیم

$$P(\text{error}) = P(w_1) - \int \left[P(w_1) \times \frac{1}{\pi b} \frac{1}{1 + \left(\frac{x-a_1}{b}\right)^2} - P(w_2) \frac{1}{\pi b} \frac{1}{1 + \left(\frac{x-a_2}{b}\right)^2} \right] dx$$


$$P(\text{error}) = P(w_1) - \left[P(w_1) \frac{1}{\pi} \tan^{-1} \left(\frac{x-a_1}{b} \right) \Big|_{-\infty}^{x=\frac{a_1+a_2}{2}} - P(w_2) \frac{1}{\pi} \tan^{-1} \left(\frac{x-a_2}{b} \right) \Big|_{-\infty}^{x=\frac{a_1+a_2}{2}} \right]$$

$$P(\text{error}) = \frac{1}{2} - \frac{1}{2\pi} \tan^{-1} \left(\frac{a_2-a_1}{2b} \right) + \frac{1}{2\pi} \tan^{-1} \left(\frac{a_1-a_2}{2b} \right)$$

$$P(\text{error}) = \frac{1}{2} - \frac{1}{\pi} \tan^{-1} \left(\frac{a_2-a_1}{2b} \right) \quad \checkmark$$

فرض $u = \frac{a_2-a_1}{b} \Rightarrow P(\text{error}) = \frac{1}{2} - \frac{1}{\pi} \tan^{-1} \left(\frac{u}{2} \right)$

(ب)



(ج) به صورت شهودی بهترین مقدار خطا وقتی رخ دهد که مثلاً هم w_1 ها یا w_2 تسخیر دهیم (و یعنی دو فوکار همپوشانی داشته اند) یعنی مثلاً در حالتی که دو توزیع نرمال داشته باشیم و دو توزیع گالسی به هم منطبق نباشند ناهمپوشانی خطا در اینجا رخ می دهد

حال اگر دو فوکار همپوشانی داشته باشند بیشترین خطا $\max(P(w_1), P(w_2))$ می شود که یعنی بیشترین خطا برابر 0.5 خواهد بود

از راه دیگری هم داریم

$$\frac{dP(\text{error})}{dx} = 0 \quad \text{حالت} \quad \Rightarrow \textcircled{1} \quad a_1 = a_2 = a$$

$$\Rightarrow P(x|w_1) = P(x|w_2) = \frac{1}{\pi b} \frac{1}{1 + \left(\frac{x-a}{b}\right)^2}$$

$$P(\text{error}) = P(w_1) - \int \left[P(w_1) \cdot P(x|w_1) - P(w_2) \cdot P(x|w_2) \right] dx = 0$$

$$P(\text{error}) = P(w_1) = 0.5$$

$$f(x_1, \dots, x_n | p_1, \dots, p_m) = \frac{n!}{\prod x_i!} \prod p_i^{x_i} \quad (۱ الف)$$

$$\text{Likelihood } \hat{p} = \arg \max_p P(x|p)$$

$$L(p) = \frac{n!}{\prod x_i!} \prod p_i^{x_i} \quad \text{وگذا} \quad \log L(p) = \log n! - \sum_{i=1}^n \log x_i! + \sum_{i=1}^n x_i \log p_i$$

برای پیدا کردن Max باید مشتق بگیریم و مشتق را برابر صفر قرار دهیم

$$\nabla_p(L(p)) = 0 + 0 + \sum \frac{x_i}{p_i} = 0 \quad \text{می بینیم این روش پاسخ ندارد}$$

$$1 - \sum_{i=1}^m p_i = 0 \quad \text{چون} \quad \sum_{i=1}^m p_i = 1 \quad \text{می بینیم. می توانیم استفاده می کنیم. از روش لاگرانژ استفاده می کنیم.}$$

$$L(p, \lambda) = \log n! - \sum_{i=1}^n \log x_i! + \sum_{i=1}^n x_i \log p_i + \lambda (1 - \sum p_i)$$

$$\nabla_p(L(p, \lambda)) = 0 + 0 + \sum \frac{x_i}{p_i} - \sum \lambda$$

$$\nabla_p(L(p, \lambda)) = 0 \quad \rightarrow \quad \boxed{p_i = \frac{x_i}{\lambda}}$$

$$\sum p_i = 1 \quad \rightarrow \quad \sum \frac{x_i}{\lambda} = 1 \quad \rightarrow \quad \sum x_i = \lambda \quad \rightarrow \quad \lambda = n$$

می بینیم که x_i ها تعداد ظاهر شدن هر وجه است. ما به صورت کلی n بار پرتاب کرده بودیم پس $\sum x_i = n$ خواهد بود پس طبق

$$\boxed{p_i = \frac{x_i}{n}}$$

$$X \sim \text{unif}([0, \theta]) \quad \rightarrow \quad P(x|\theta) = \frac{1}{\theta} \quad 0 \leq x_i \leq \theta \quad (ب)$$

$$P(x_1, x_2, \dots, x_n | \theta) = \frac{1}{\theta^n} = L(\theta) \quad n \text{ نمونه}$$

$$\log L(\theta) = -n \log \theta \quad \rightarrow \quad \nabla_{\theta} L(\theta) = \frac{-n}{\theta} = 0 \quad \rightarrow \quad \text{جواب مشخصی ندارد}$$

برای minimize کردن θ باید نهایتاً θ بزرگترین x_i باشد تا x_i ها

در بازه $0 \leq x_i \leq \theta$ قرار بگیرند یعنی $x_i \leq \theta$ و همه x_i ها باید یک شوند

و رابطه $\theta \leq \max(x_1, \dots, x_n)$ برقرار باشد. در نهایت داریم

$$\hat{\theta} = \max(x_1, \dots, x_n)$$

(ج) فرض می‌کنیم که یک $M \leq \theta$ با احتمال 1 داریم که رابطه $M = M_{\theta} \propto n_i$ در آن برقرار باشد و μ یک bias estimator باشد توزیع تخمین آن به صورت زیر است

$$P(M \leq m) = P(n_1 \leq m, n_2 \leq m, \dots, n_m \leq m) = \left(\frac{m}{\theta}\right)^n$$

اگر از رابطه بالا امید ریاضی بگیریم داریم

$$E_{\theta}(M_n) = \int_0^{\theta} P(M \geq m) dm = \int_0^{\theta} \left(1 - \left(\frac{m}{\theta}\right)^n\right) dm = \theta - \frac{\theta}{n+1} = \frac{n}{n+1} \theta$$

همینطور که مشاهده می‌شود $M \neq \theta$ است و یعنی این تخمینگر biased است و کاملاً به نمونه‌های بستگی دارد

(د) $f(x) = \frac{\lambda^n e^{-\lambda}}{n!}$ توزیع پواسون

نمونه n $P(x_1, \dots, x_n | \lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = L(\lambda)$

$L(\lambda) = e^{-\lambda n} \frac{\lambda^{\sum x_i}}{\prod x_i!}$ $\rightarrow \log(L(\lambda)) = -\lambda n + \log(\lambda) \sum_{i=1}^n x_i - \log(\prod x_i!)$

$\nabla_{\lambda} \log(L(\lambda)) = \frac{d}{d\lambda} \log(L(\lambda)) = -n + \frac{\sum x_i}{\lambda} = 0$

$\rightarrow \hat{\lambda} = \frac{\sum x_i}{n}$
 $\hat{\lambda}_{\text{اصلی}} = \frac{\sum x_i}{n}$
 مشاهده می‌شود تخمین که به است آمده میانگین نمونه‌هاست و به این λ اصلی هم میانگین نمونه‌هاست پس $\hat{\lambda}$ است unbiased است.

(ک) الف) $P(\mu | x) = \frac{P(x | \mu) P(\mu)}{P(x)}$ $x \sim N(\mu, \Sigma)$ $\mu \sim N(\mu_0, \Sigma_0)$

$\hat{\mu}_{\text{map}} = \arg \max_{\mu} P(\mu | x)$

$P(D | \mu) = \prod_{k=1}^n P(x_k | \mu)$

می‌فهمیم از likelihood و استفاده کنیم پس

$\log P(D | \mu) = \log \left(\prod_{k=1}^n P(x_k | \mu) \right) = \sum_{k=1}^n \log P(x_k | \mu)$

پس $P(x_i | \mu) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)\right)$

جابیناری می‌کنیم

$$\log P(D|\mu) = -\frac{n}{2} \log((2\pi)^d |\Sigma|) - \frac{1}{2} \sum_{k=1}^n (\alpha_k - \mu)^T \Sigma^{-1} (\alpha_k - \mu)$$

$$\log P(\mu) = -\frac{n}{2} \log((2\pi)^d |\Sigma_0|) - \frac{1}{2} (\mu - m_0)^T \Sigma_0^{-1} (\mu - m_0)$$

حال که $\log P(\mu)$ و $\log P(D|\mu)$ داریم به درج مناسب $\hat{\mu}_{map}$ داریم

$$\hat{\mu}_{map} = \arg \max_{\mu} P(\mu|\alpha) = \arg \max_{\mu} P(D|\mu) P(\mu)$$

که داریم سیریم، جابیناری می‌کنیم

$$\hat{\mu}_{map} = \arg \max_{\mu} \left\{ -\frac{1}{2} \sum_{k=1}^n (\alpha_k - \mu)^T \Sigma^{-1} (\alpha_k - \mu) - \frac{1}{2} (\mu - m_0)^T \Sigma_0^{-1} (\mu - m_0) \right\}$$

ب) ابتدا تبدیل فعلی $x' = Ax$ بروی می‌بینیم، کواریانس قبلی ایمال می‌کنیم

$$\mu' = E[x'] = E[Ax] = A\mu$$

$$\Sigma' = E[(x' - \mu')(x' - \mu')^T] = E[(Ax - A\mu)(Ax - A\mu)^T] = A \Sigma A^T$$

$$P(\mu') = \frac{1}{(2\pi)^d |\Sigma'|^{\frac{1}{2}}} \exp \left[-\frac{1}{2} (\mu' - m_0)^T \Sigma_0^{-1} (\mu' - m_0) \right]$$

$$P(\mu') = \frac{1}{(2\pi)^d |\Sigma_0|^{\frac{1}{2}}} \exp \left[-\frac{1}{2} (A\mu - Am_0)^T (A\Sigma_0 A^T)^{-1} (A\mu - Am_0) \right]$$

ابطه با A ساده می‌کنیم و A^{-1} و A با هم ساده می‌شوند

$$P(\mu') = \frac{1}{(2\pi)^d |\Sigma_0|^{\frac{1}{2}}} \exp \left[-\frac{1}{2} (\mu - m_0)^T \Sigma_0^{-1} (\mu - m_0) \right]$$

$$\log P(\mu') = -\frac{n}{2} \log((2\pi)^d |\Sigma_0|) - \frac{1}{2} (\mu - m_0)^T \Sigma_0^{-1} (\mu - m_0)$$

حال $P(D'|\mu')$ را بررسی می‌کنیم. برای ساده ابتدا \log سیریم، حساب است که در

$$\log(P(D'|\mu')) = -\frac{n}{2} \log((2\pi)^d |A\Sigma A^T|) - \sum_{k=1}^n \frac{1}{2} (A\alpha_k - A\mu)^T (A\Sigma A^T)^{-1} (A\alpha_k - A\mu)$$

$$\log(P(D'|\mu')) = -\frac{n}{2} \log((2\pi)^d |A\Sigma A^T|) - \frac{1}{2} \sum_{k=1}^n (\alpha_k - \mu)^T \Sigma^{-1} (\alpha_k - \mu)$$

دوباره A و A^{-1} ها ساده می‌شوند، و در نهایت بعضی از Σ و بعضی از Σ^{-1} ها با هم ساده می‌شوند، بنابراین برای μ است.

$$\hat{\mu}' = \arg \max_{\mu'} \log \{ P(D'|\mu') P(\mu') \} = \arg \max_{\mu} \left\{ -\frac{1}{2} \sum_{k=1}^n (\alpha_k - \mu)^T \Sigma^{-1} (\alpha_k - \mu) - \frac{1}{2} (\mu - m_0)^T \Sigma_0^{-1} (\mu - m_0) \right\}$$

(4) الف) Naive Bayes : به روشی از classifier ها گفته می شود که فرض می کنند

بین متغیرهای تصادفی استقلال وجود دارد. این classifier تحت خوبی دارد

$$P(C_k | x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n | C_k) P(C_k)}{P(x)}$$

$$P(C_k | x_1, \dots, x_n) = P(C_k) \prod_{i=1}^n P(x_i | C_k)$$

Optimal Bayes : متغیرهای تصادفی از هم مستقل نیستند و برای پیدا کردن

\hat{y} باید بیشترین احتمال را پیدا کنیم

$$\hat{y} = \arg \max_{y \in Y} P(y | x)$$

(5) ابتدا کد و نتایج آن را مشاهده میکنیم

```
In [1]: import cv2
import glob
from PIL import Image
import numpy as np
```

```
In [2]: Tp = 0
Fn = 0
Fp = 0
Tn = 0
for name in glob.glob('Images\*[0-9].*'):
    img = cv2.imread(name, cv2.IMREAD_UNCHANGED)
    height, width, x = img.shape
    rgb=[0,0,0]
    for i in range(height):
        for j in range(width):
            rgb += img[i,j]
    if (name[7] == 'c' and rgb[2]<rgb[0]):
        Tp += 1
    if (name[7] == 'c' and rgb[2]>rgb[0]):
        Fn += 1
    if (name[7] == 'm' and rgb[2]<rgb[0]):
        Fp += 1
    if (name[7] == 'm' and rgb[2]>rgb[0]):
        Tn += 1
```

```
In [3]: print('      c      |      m')
print('-----')
print('c | TP= ',Tp,' |   FN= ',Fn,' |   recall= ',Tp/(Tp+Fn))
print('-----')
print('m | FP= ',Fp,' |   TN= ',Tn,' |   specificity= ',Tn/(Tn+Fp))
print('-----')
print('      percision= ',Tp/(Tp+Fp),' | negetive predictive value =',Tn/(Tn+Fn))
print('      Accuracy=',(Tp+Tn)/(Tp+Tn+Fn+Fp))
```

	c		m	
c	TP= 46		FN= 18	recall= 0.71875
m	FP= 1		TN= 57	specificity= 0.9827586206896551
	percision= 0.9787234042553191		negetive predictive value = 0.76	
	Accuracy= 0.8442622950819673			

نتایج به خوبی نشان میدهد طبقه بندی که طراحی کردیم توانسته منچستر را جدا کند ولی دقت آن برای چلسی کمتر بوده است. در کل دقتی بیشتر از 97 درصد داریم که خوب است. ولی recall به نسبت ضعیف بوده است.


(6

ج)

part 3 : naive bayes with library

```
[ ] 1 from sklearn import datasets
    2 import pandas as pd
    3 df_iris = pd.read_csv('Iris.csv')
```

```
1 df_iris.head()
```



	Sepal_Length	Sepal_Width	Petal_Length	Petal_Width	Class
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

```
[ ] 1 from sklearn.model_selection import train_test_split
    2
    3 X = df_iris[['Sepal_Length', 'Sepal_Width',
    4             'Petal_Length', 'Petal_Width']]
    5
    6 y = df_iris['Class']
    7
    8 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
    9                                                    random_state=8)
```

```
[ ] 1 from sklearn.naive_bayes import GaussianNB
    2
    3 clf = GaussianNB()
    4
    5 # fitting the classifier
    6 clf.fit(X_train, y_train);
```

```
[ ] 1 y_pred = clf.predict(X_test)
    2
    3 from sklearn.metrics import accuracy_score
    4
    5 print("The accuracy of the model is: %.1f%%" % (accuracy_score(y_test, y_pred)*100))
```


The accuracy of the model is: 86.7%

```
▶ 1 from sklearn.model_selection import cross_val_score
    2 import numpy as np
    3 acc = cross_val_score(clf, X, y, cv=5, scoring='accuracy')
    4
    5 print(acc)
    6
    7 print("\nwe are 95 percent confident that our accuracy is within: %.2f%% +- %.2f%%"
    8       |%(np.mean(acc)*100, 2 * np.std(acc) / np.sqrt(5) *100))
```

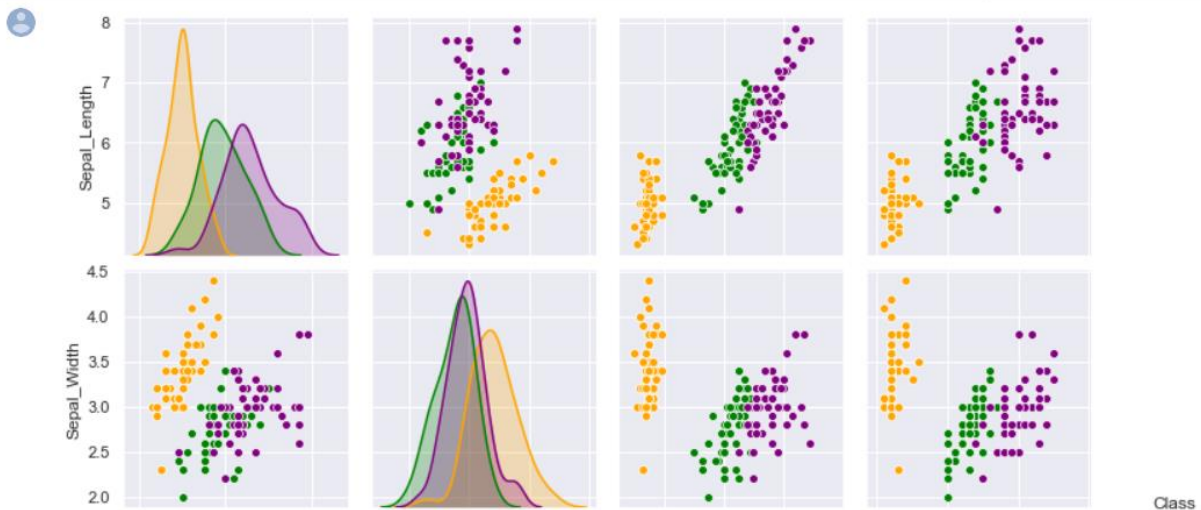
```
▶ [0.93333333 0.96666667 0.93333333 0.93333333 1.          ]
```

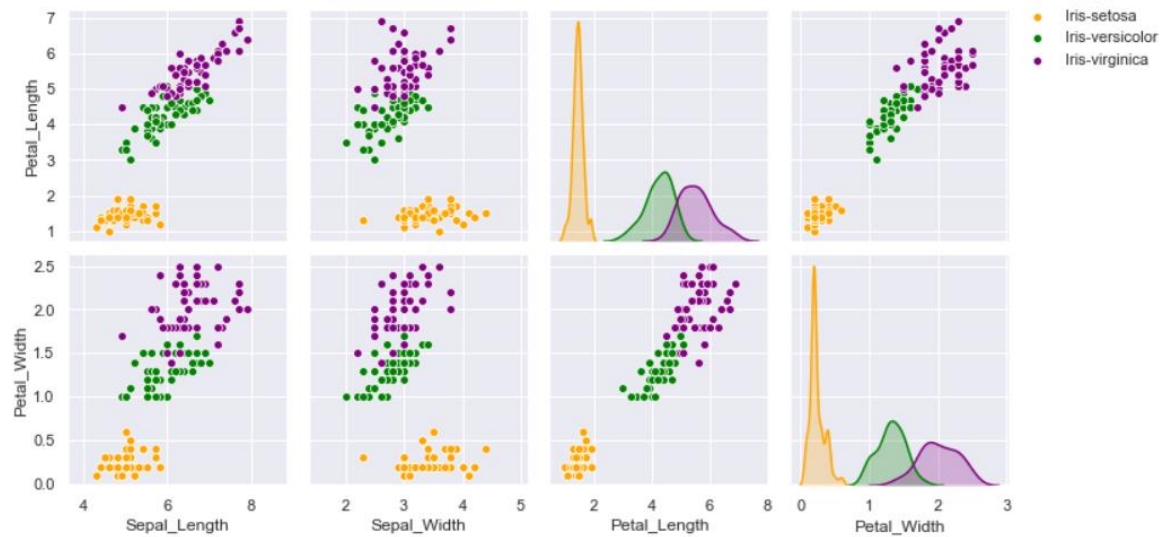
we are 95 percent confident that our accuracy is within: 95.33% +- 2.39%


```
[ ] 1 from sklearn.metrics import confusion_matrix
    2 %matplotlib inline
    3 import numpy as np
    4 import matplotlib.pyplot as plt
    5 import seaborn as sns; sns.set()
    6 confusion_mtx = confusion_matrix(y_test, y_pred)
    7 target=['setosa', 'versicolor', 'virginica']
    8 sns.heatmap(confusion_mtx.T, square=True, annot=True, fmt='d', cbar=False,
    9             xticklabels=target, yticklabels=target)
   10 plt.xlabel('true label')
   11 plt.ylabel('predicted label');
   12
```



```
1 palette = {'Iris-setosa': 'orange', 'Iris-versicolor': 'green', 'Iris-virginica': 'purple'}
2
3 g = sns.pairplot(df_iris, vars = df_iris.columns[0:4], hue="Class", palette=palette)
```





```
1 from sklearn.metrics import classification_report
2
3 print(classification_report(y_test, y_pred, target_names=target))
```

	precision	recall	f1-score	support
setosa	1.00	1.00	1.00	10
versicolor	0.78	0.78	0.78	9
virginica	0.82	0.82	0.82	11
accuracy			0.87	30
macro avg	0.87	0.87	0.87	30
weighted avg	0.87	0.87	0.87	30