

(1)

$$P(\alpha) = \frac{1}{n h_n} \sum_{i=1}^n \varphi\left(\frac{x - \alpha_i}{h_n}\right) \quad \begin{matrix} \rightarrow \varphi(\alpha) \sim N(0, 1) \\ \rightarrow P(\alpha) \sim N(\mu, \sigma^2) \end{matrix} \quad (1)$$

$$\textcircled{1} E[P(\alpha)] = E\left[\frac{1}{n h_n} \sum_{i=1}^n \varphi\left(\frac{x - \alpha_i}{h_n}\right)\right] = \frac{1}{n h_n} \sum_{i=1}^n E\left[\varphi\left(\frac{x - \alpha_i}{h_n}\right)\right] = \frac{1}{n h_n} \sum_{i=1}^n \varphi\left(\frac{x - \alpha_i}{h_n}\right) P(\alpha) d\alpha$$

$$\begin{aligned} \tilde{P}_n(\alpha) &= \sum \varphi\left(\frac{x - \alpha_i}{h_n}\right) P(\alpha) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2 h_n^2}\right) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2 \sigma^2}\right) \\ &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2(\sigma^2 + h_n^2)}\right) \sim N(\mu, h_n^2 + \sigma^2) \end{aligned}$$

$$\begin{aligned} \textcircled{2} P(\alpha) - \tilde{P}_n(\alpha) &= \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2 \sigma^2}\right] - \frac{1}{\sqrt{2\pi} \sqrt{h_n^2 + \sigma^2}} \exp\left[-\frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)}\right] \\ &= \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2 \sigma^2}\right] \left(1 - \frac{1}{\sqrt{h_n^2 + \sigma^2}} \exp\left[-\frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)}\right]\right) \\ &\quad \underbrace{\qquad\qquad\qquad}_{P(\alpha)} \qquad\qquad\qquad \underbrace{\qquad\qquad\qquad}_{\substack{\text{با توجه به } h_n \rightarrow 0 \Rightarrow \frac{1}{\sigma} \left[1 + \frac{h_n^2}{\sigma^2}\right] \quad \text{با توجه به } h_n \rightarrow 0 \Rightarrow 1 - \frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)}}} \end{aligned}$$

$$\begin{aligned} \rightarrow P_n(\alpha) - \tilde{P}_n(\alpha) &= \left[1 - \frac{1}{\sigma} \left[1 + \frac{h_n^2}{\sigma^2}\right] \left[1 - \frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)}\right]\right] P(\alpha) \\ &= \left[1 - \frac{1}{\sigma} \left(1 + \frac{h_n^2}{\sigma^2} - \frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)} - \frac{h_n^2 (x - \mu)^2}{2 \sigma^2 (h_n^2 + \sigma^2)}\right)\right] P(\alpha) \end{aligned}$$

چون h_n کوچک است پس می توان در برابر σ از آن صرف نظر کرد

$$\rightarrow P_n(\alpha) - \tilde{P}_n(\alpha) = \frac{1}{\sigma} \left(\frac{h_n^2}{\sigma^2}\right) \left[1 - \left(\frac{x - \mu}{\sigma}\right)^2\right] P(\alpha)$$

$$\begin{aligned} \textcircled{3} \text{Var}(P_n(\alpha)) &= \text{Var}\left(\frac{1}{n h_n} \sum \varphi\left(\frac{x - \alpha_i}{h_n}\right)\right) = \frac{1}{n^2 h_n^2} \left[E\left(\varphi\left(\frac{x - \mu}{h_n}\right)^2\right) - E\left(\varphi\left(\frac{x - \mu}{h_n}\right)\right)^2\right] \\ &= \frac{1}{n^2 h_n^2} \left[\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{h_n^2}\right) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2 \sigma^2}\right) d\alpha - \left[\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)}\right) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2 \sigma^2}\right) d\alpha\right]^2\right] \\ &= \frac{1}{n^2 h_n^2} \left[\underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{(x - \mu)^2}{h_n^2}\right) P_n(\alpha) d\alpha}_{\substack{\text{با توجه به } h_n : \frac{1}{\sqrt{2\pi}} n h_n P_n(\alpha)}} - \underbrace{\frac{h_n^2}{\sqrt{h_n^2 + \sigma^2}} \times \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2(h_n^2 + \sigma^2)}\right]}_{\substack{\text{با توجه به } h_n \rightarrow 0}}\right] \end{aligned}$$

$$\text{Var}(P_n(\alpha)) = \frac{1}{n^2 h_n^2} \times \frac{1}{\sqrt{2\pi}} n h_n P_n(\alpha) = \frac{P_n(\alpha)}{\sqrt{2\pi} h_n n}$$

$$D(a, b) = \sqrt{\sum_{k=1}^d (a_k - b_k)^2} \quad \leadsto \quad x'_k = a_k \quad x_k \quad (2)$$

① فاصله ی بین نا منفی باشد

$$D'(x, y) = \sqrt{\sum_{k=1}^d (x'_k - y'_k)^2} \geq 0 \Rightarrow (x'_k - y'_k)^2 \geq 0 \Rightarrow (a'_k x_k - b'_k x_k)^2 \geq 0$$

لایحه ی ۰ همیشه برقرار است زیرا آنکه تفاضل ۲ بتواند برابر ۰ همیشه می شود.

② فاصله ی خودی ۰ باشد با فاصله ی خودی برابر باشد

$$D'(x, x) = \sqrt{\sum_{k=1}^d (x'_k - x'_k)^2} = \sqrt{\sum_{k=1}^d (y'_k - y'_k)^2} = D'(y, y)$$

③ مجموع فاصله ی خودی و ۲ دیگر بیشتر مساوی فاصله ی ۱ و ۲ باشد

$$D'(x, y) + D'(y, z) \geq D'(x, z)$$

فرض کنیم (۱) و (۲) را یکی بکنیم

$$D'(x, y) = (x'_k - y'_k)^2 \quad D'(y, z) = (y'_k - z'_k)^2 \quad D'(x, z) = (x'_k - z'_k)^2$$

$$(x'_k - y'_k)^2 + (y'_k - z'_k)^2 \geq (x'_k - z'_k)^2$$

$$\underline{x_k^2} - 2x_k y_k + \underline{y_k^2} + \underline{y_k^2} - 2y_k z_k + \underline{z_k^2} \geq \underline{x_k^2} - 2x_k z_k + \underline{z_k^2}$$

$$2y'_k (y'_k - x'_k - z'_k) \geq -2x'_k z'_k \leadsto y'_k + x'_k z'_k - y'_k x'_k - y'_k z'_k \geq 0$$

$$y'_k (y'_k - x'_k) - z'_k (y'_k - x'_k) \geq 0 \leadsto (y'_k - z'_k) (y'_k - x'_k) \geq 0$$

این لایحه همیشه برقرار است

در $k=n$ از این دو فرمول استفاده می کنند تا حجم محاسبات کاهش یابد.

(3)

(۳)

این خطا در حالتی رخ می دهد که x عضو کلاس w_1 باشد ولی label آن w_2 نشود (راه ساده تر و به سادگی است):

$$P(\text{error}) = P(x \in D_1 | w_2) + P(x \in D_2 | w_1)$$

چون هر دو توزیع یکسانند و مرکز آنها $\frac{1}{2}$ فاصله فاصله دارد پس احتمال فضای D_1 و D_2 برای هر یک

$$P(\text{error}) = 2P(x \in D_1 | w_2)$$

حال فرض می کنیم در هر مرحله j داده label اشتباه بخورند یعنی $\frac{k-1}{2}$

$$P(\text{error}) = \frac{1}{2^Q} \sum_{j=0}^{\frac{k-1}{2}} \binom{Q}{j}$$

ب) در حالتی که k خیلی بزرگ نیست احتمال خطاها جمع می شود پس بهترین حالت وقتی است که کمترین تعداد خطا داشته باشیم پس اگر $k \leq 2$ باشد یعنی برای مثال $k=1$ احتمال خطا برای Q برابر $\frac{1}{2^Q}$ می شود که می بینیم صاف است

$$\lim_{Q \rightarrow \infty} P(\text{error}) = \lim_{Q \rightarrow \infty} \frac{1}{2^Q} \sum_{j=0}^{\frac{k-1}{2}} \binom{Q}{j} = 0 \quad (2)$$

سرعت رشد 2^Q خیلی بیشتر از $\sum_{j=0}^{\frac{k-1}{2}} \binom{Q}{j}$ است.

(ع) بخش اول

— پارامتر h_n در پارزن نشان دهنده میزان Sharp یا Smooth بودن است به طوری که اگر h_n کم باشد منحنی smooth تر می شود و هر چه h_n بزرگتر باشد منحنی sharp تر می شود برای h_n کم، داریس کم و بایس زیاد است و بر h_n زیاد داریس زیاد و بایس کم است.

— در روش پارامتریک با کمک دیتاها یک توزیع تعین می کنیم که بعد از تعین توزیع دیتا نیازی به دیتا نداریم و می توانیم در هر مرحله به تمام داده ها نیاز نداریم و در مقام این در روش می توان گفت روش پارامتریک کم هزینه تر است و حافظه کمتری نیاز دارد و در روش نان پارامتریک دقت بیشتر است و به حافظه و هزینه بیشتری نیاز است.

— همانطور که گفته شد مشکل روش های kernel based این است که همیشه به دیتاها نیاز است و به دیتاها نیاز داریم زیرا برای هر دیتا سبب افزایش هزینه و افزایش حافظه می شود و کند شدن سرعت می شود.

— در روش پارزن با ثابت نگه داشتن حجم تعداد دیتاهای موجود در حجم ما اندازه می گیریم و در روش knn با ثابت کردن تعداد دیتا، حجم ما متغیر می کنیم.

بخش دوم


(ج) در روش knn، تعداد نقاط یعنی k ثابت است و n متغیر می ماند حال در صورتی که بعد از ثابت شدن k ، تعداد داده ها را افزایش دهیم علاوه بر افزایش حجم محاسبات، پیچیدگی محاسبه فاصله نیز افزایش می یابد و این افزایش (زحمتی که صرفاً بعد از افزایش یا به ضعیف تر است Curse of dimensionality) افزایش می دهد سبب افزایش محاسبات می شود و باید بدانیم تعداد داده ها هم با همان سرعت افزایش یابد.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.spatial.distance import pdist
```

```
def make_data(N, d , rseed=1):
    rand = np.random.RandomState(rseed)
    x = rand.randn(N*d)
    x = np.reshape(x , (N , d))
    return x

def distance(x , N , d):
    x_distance = []
    for i in range(N-1):
        for j in (i+1 ,N-1) :
            dist = 0
            for dim in range(d):
                dist = dist + np.power(x[i][dim]-x[j][dim],2)
            x_distance.append(np.sqrt(dist))
    return x_distance
```

```
x = make_data(1000 , 5)
x_distance = distance(x ,1000 , 5)
hist_distance = plt.hist(x_distance, bins=40, density=True)
plt.title("5 Dimension-1000 DataPoint")
plt.xlabel("Distance")
```



(5

```
import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
from sklearn.neighbors import KernelDensity
```

```
ted = pd.read_csv('ted_main.csv')
ted.head()
```



```
ted_duration = ted.duration
f, ax = plt.subplots(figsize=(7, 7))
ax.scatter(ted_duration, ted_duration,
           marker='o', color='green', s=4, alpha=0.3)
```

```
def gaussian_kernel(x):
    return (1 / (np.sqrt(2 * np.pi))) * np.exp((-0.5) * (x**2))

def parzen_window_func(x_vect, h, x):
    parzen = []
    for x_i in x:
        k_n = 0
        for j in range(len(x_vect)):
            k_n = k_n + gaussian_kernel((x_i - x_vect[j])/h)
        parzen.append(k_n / (len(x_vect) * h))
    return parzen
```

```
h = [10, 20, 50, 100]
count = np.arange(2000)
for i in h:
    estimation = parzen_window_func(ted_duration, i, count)
    plt.legend('{}'.format(i))
    plt.plot(x, estimation)
plt.title("parzen estimator without library")
plt.show()
```

```
h = [10, 20, 50, 100]
for i in range(250, len(ted_duration), 250):
    window = KernelDensity(kernel = "gaussian", bandwidth = 10)
    window.fit(ted_duration.reshape(-1, 1))
    plt.plot(ted_duration, np.exp(window.score_samples(ted_duration.reshape(-1, 1))))
plt.title("parzen estimator with library")
plt.show()
```



(6

```
import numpy as np
import pandas as pd
from sklearn.neural_network import MLPClassifier
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
```

```
def mlp(Xtrain, Xtest, Xvalid, Ytrain, Ytest, Yvalid, Solver, lr, layers, neurons):
    clf = MLPClassifier(solver = Solver, learning_rate = "constant", learning_rate_init = lr
                        , hidden_layer_sizes = (neurons, layers))
    clf.fit(Xtrain, Ytrain)
    plt.plot(clf.loss_curve_)
    clf.fit(Xvalid, Yvalid)
    plt.plot(clf.loss_curve_)
    plt.legend(["train", "validation"])
    plt.title("loss diagram => solver={} layers_number={} neurons_number={} learning_rate={} ".format(Solver,
                                                                                                  layers, neurons, lr))

    plt.show()
    Ypred = clf.predict(Xtest)
```

```
train = pd.read_csv('fashion-mnist_train.csv')
y_train = train['label']
x_train = train
del x_train['label']


test = pd.read_csv('fashion-mnist_test.csv')
y_test = test['label']
x_test = test
del x_test['label']

x_train, x_valid, y_train, y_valid = train_test_split(x_train, y_train, test_size = 0.2)
```


```
layer = [1,2]
neuron = [100]
solver = ['sgd', 'adam']
learning_rate = [0.1,0.5]

for S in solver:
    for LR in learning_rate:
        for L in layer:
            for N in neuron:
                mlp(x_train, x_test, x_valid, y_train, y_test, y_valid, S, LR, L, N)
```


loss diagram => solver=sgd layers_number=1 neurons_number=100 learning_rate=0.1




loss diagram => solver=sgd layers_number=2 neurons_number=100 learning_rate=0.1




loss diagram => solver=sgd layers_number=2 neurons_number=100 learning_rate=0.5




loss diagram => solver=sgd layers_number=1 neurons_number=100 learning_rate=0.5




loss diagram => solver=adam layers_number=2 neurons_number=100 learning_rate=0.1




loss diagram => solver=adam layers_number=1 neurons_number=100 learning_rate=0.1



loss diagram => solver=adam layers_number=2 neurons_number=100 learning_rate=0.5



loss diagram => solver=adam layers_number=1 neurons_number=100 learning_rate=0.5




```
import matplotlib.pyplot as plt
import numpy as np
```

```
def Perceptron(X, W, Y, LR):
    Sum = 0
    for i in range(len(W)):
        Sum += X[i] * W[i]
    if Sum > 0:
        Ypred = 1
    else:
        Ypred = 0
    if Y != Ypred:
        err = Y - Ypred
        for i in range(len(W)):
            W[i] = W[i] + (LR * err)
    return W
```

```
learning_rate = 0.1
weight = [0.8, 0.8, 0.8]

x = [2, 2.5, 3, 0, 1, 1, 2, 2, 3, 3]
y = [0, 0, 0, 0, -1, 1, -2, 2, -3, 3]
Label = [1, 1, 1, 0, 0, 0, 0, 0, 0, 0]

for i in range(50):
    for j in range(len(Label)):
        Weights = Perceptron([x[j], y[j], 1], weight, Label[j], learning_rate)
```

```

x_line = np.arange(len(x))
first_line = []
for i in x_line:
    first_line.append((i * weights[0]) + (i * weights[1]))
second_line = []
for i in x_line:
    second_line.append((-1 * i * weights[0]) - (i * weights[1]))
plt.scatter(x[:3], y[:3], c = "red")
plt.scatter(x[3:], y[3:], c = "blue")
plt.plot(x_line, first_line, c = "purple")
plt.plot(x_line, second_line, c = "purple")
plt.title("mlp")

```

Text(0.5, 1.0, 'mlp')

