


سؤال (۱۱) VC dimension تعداد نقاطی که می توان با شاتر shatter یا جدا کرد که این اندازه گیری میزان ظرفیت (پویایی یا انعطاف پذیری) ماتریس می دهد.

VC dimension به عنوان مقدار توانایی و قدرت بندی یک فضا استفاده می شود که نشان دهد بیشترین مجموعه ای که می توان با شاتر shatter کرد که نشان دهد این است که یک طبقه از فضا به روی آن می تواند به آسانی جدا شود.



بنابراین VC dimension برای یک طبقه خطی حداکثر برابر ۳ و کمتر از ۴ است.

سؤال (۲)

الف)

PCA: ماتریس Covariance می تواند به صورت $N \times N$ برای تقارن $N \times N$ ماتریس $N^2 \times N^2$ به صورت $N \times N$ برای جلوگیری از این اتفاق ماتریس $N \times N$ می باشد که N تعداد ویژگی ها است. سپس مقدار ویژه ماتریس محاسب کرده و با کمک بردار ویژه ها می توانیم آن را کاهش دهیم.

LDA: که ابعاد زیاد است با S (Singular) می شود. $S_{Buk} = \lambda_k u_k$ برای جلوگیری از این مشکل ابتدا با PCA بعد ها کم کرده و سپس LDA می زنیم.

$$X_1 = \left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 3 \\ 1 \end{pmatrix}, \begin{pmatrix} 4 \\ 1 \end{pmatrix}, \begin{pmatrix} 5 \\ 1 \end{pmatrix} \right\} \quad \mu_1 = \left\{ \begin{pmatrix} 1.0 \end{pmatrix} \right\} \quad (ع)$$

$$X_2 = \left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 3 \\ 1 \end{pmatrix}, \begin{pmatrix} 4 \\ 1 \end{pmatrix}, \begin{pmatrix} 5 \\ 1 \end{pmatrix} \right\} \quad \mu_2 = \left\{ \begin{pmatrix} 1.1 \end{pmatrix} \right\}$$

$$S_1 = \sum_{x \in C_1} (x - \mu_1)(x - \mu_1)^T = \begin{bmatrix} 1.14 & -1.0 \end{bmatrix} \begin{bmatrix} 1.14 & -1.0 \end{bmatrix}^T = \begin{bmatrix} 1.14 & -1.0 \\ -1.0 & 1.0 \end{bmatrix}$$

$$S_2 = \sum_{x \in C_2} (x - \mu_2)(x - \mu_2)^T = \begin{bmatrix} -0.1 & -1.1 & 0.1 & -0.1 & 1.1 \end{bmatrix} \begin{bmatrix} -0.1 & -1.1 & 0.1 & -0.1 & 1.1 \end{bmatrix}^T = \begin{bmatrix} 1.1 & -1.2 \\ -1.2 & 1.4 \end{bmatrix}$$

$$\star S_w = S_1 + S_2 = \begin{bmatrix} 1.3 & -1.2 \\ -1.2 & 1.4 \end{bmatrix}$$

$$\star S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T = \begin{pmatrix} -0.1 \\ -1.1 \end{pmatrix} \begin{pmatrix} -0.1 & -1.1 \end{pmatrix} = \begin{pmatrix} 0.01 & 0.11 \\ 0.11 & 1.21 \end{pmatrix}$$

$$J(w) = \frac{w^T S_B w}{w^T S_w w}$$

$$w^* = S_w^{-1} (\mu_1 - \mu_2) = \begin{bmatrix} -0.11 \\ -0.1 \end{bmatrix} \quad y = w^T \cdot x$$

$$X_1 = \begin{bmatrix} 1 & 2 \\ 1 & 3 \end{bmatrix} \quad X_2 = \begin{bmatrix} 4 & 3 \\ 1 & 2 \end{bmatrix} \Rightarrow \mu_1 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \quad \mu_2 = \begin{bmatrix} 2.5 \\ 1.5 \end{bmatrix} \quad (ع)$$

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T = \begin{bmatrix} -1.5 \\ 1 \end{bmatrix} \begin{bmatrix} -1.5 & 1 \end{bmatrix} = \begin{bmatrix} 2.25 & -1.5 \\ -1.5 & 1 \end{bmatrix}$$

$$S_1 = (x_{+1} - \mu_{+1})(x_{+1} - \mu_{+1})^T = \begin{bmatrix} -0.5 & 0.5 \\ -1.5 & 1.5 \end{bmatrix} \begin{bmatrix} -0.5 & -1.5 \\ 0.5 & 1.5 \end{bmatrix} = \begin{bmatrix} 0.5 & 1.5 \\ 1.5 & 2.5 \end{bmatrix} \quad (ب)$$

$$S_{-1} = (x_{-1} - \mu_{-1})(x_{-1} - \mu_{-1})^T = \begin{bmatrix} -0.5 & 0.5 \\ -0.5 & 0.5 \end{bmatrix} \begin{bmatrix} -0.5 & -0.5 \\ 0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 0.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix}$$

$$S_w = S_1 + S_{-1} = \begin{bmatrix} 0.75 & 1.75 \\ 1.75 & 2.75 \end{bmatrix}$$

$$w^* = S_w^{-1}(\mu_1 - \mu_{-1}) = \begin{bmatrix} -1.28 \\ 0.5 \end{bmatrix} \rightarrow Z = [-1.28 \quad 0.5] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (ج)$$

x_i^T	y_i	z_i
(1, 1)	1	-1.28
(2, 2)	1	-1.28
(2, 0.5)	-1	-1.28
(2, 2)	-1	-1.28


	x_1	x_2
x_1^T	0	2
x_2^T	0	0
x_c^T	4.5	0
x_ε^T	5	0
x_w^T	5	2

$$C_1 = \{x_1, x_2, x_\varepsilon\}$$

$$C_2 = \{x_c, x_w\}$$

$$L_1 \text{-norm} = \|x\|_1 = |x_1|$$

$$L_2 \text{-norm} = \|x\|_2 = \sqrt{x_1^2 + x_2^2}$$



$$C_1 \rightarrow \mu_1 = \begin{bmatrix} 5/3 \\ 2/3 \end{bmatrix}$$

$$C_2 \rightarrow \mu_2 = \begin{bmatrix} 3.25 \\ 1 \end{bmatrix}$$

$$\|x_1 - \mu_1\| = \sqrt{4.5^2}$$

$$\|x_2 - \mu_1\| = \sqrt{2^2}$$

$$\|x_c - \mu_1\| = \sqrt{0.5^2 + 2^2}$$

$$\|x_\varepsilon - \mu_1\| = \sqrt{1^2 + 5^2}$$

$$\|x_w - \mu_1\| = \sqrt{1^2 + 1^2}$$

$$\|x_1 - \mu_2\| = \sqrt{11.5^2 + 2^2}$$

$$\|x_2 - \mu_2\| = \sqrt{11.5^2 + 2^2}$$

$$\|x_c - \mu_2\| = \sqrt{1.25^2 + 2^2}$$

$$\|x_\varepsilon - \mu_2\| = \sqrt{1.25^2 + 2^2}$$

$$\|x_w - \mu_2\| = \sqrt{1.25^2 + 2^2}$$

الف

$$\|x_1 - \mu_1\| = 1.82$$

$$\|x_2 - \mu_1\| = 0.13$$

$$\|x_3 - \mu_1\| = 1.2$$

$$\|x_4 - \mu_1\| = 4.55$$

$$\|x_5 - \mu_1\| = 9.49$$

$$\|x_1 - \mu_2\| = 2.04$$

$$\|x_2 - \mu_2\| = 0.09$$

$$\|x_3 - \mu_2\| = 3.48$$

$$\|x_4 - \mu_2\| = 1$$

$$\|x_5 - \mu_2\| = 1$$

$$\rightarrow C_1 = \{x_1, x_2, x_3\}$$

$$C_2 = \{x_4, x_5\}$$

با توجه به اینکه دسته‌ها دیگر تفسیر نمی‌کنند پس خروجی نهایی نیز همین دسته‌ها خواهد بود

$$C_1 \rightarrow \begin{bmatrix} 0.9 \\ 2.9 \end{bmatrix} = \mu_1$$

$$C_2 \rightarrow \mu_2 = \begin{bmatrix} 3.25 \\ 1 \end{bmatrix}$$

(ب)

$$\|x_1 - \mu_1\| = 3$$

$$\|x_2 - \mu_1\| = 2.3$$

$$\|x_3 - \mu_1\| = 0.13$$

$$\|x_4 - \mu_1\| = 4$$

$$\|x_5 - \mu_1\| = 15.4$$

$$\|x_1 - \mu_2\| = 4.25$$

$$\|x_2 - \mu_2\| = 4.25$$

$$\|x_3 - \mu_2\| = 2.55$$

$$\|x_4 - \mu_2\| = 2.75$$

$$\|x_5 - \mu_2\| = 2.75$$

$$\rightarrow C_1 = \{x_1, x_2, x_3\} \rightarrow \mu_1 = \begin{bmatrix} 0.9 \\ 2.9 \end{bmatrix}$$

$$C_2 = \{x_4, x_5\} \rightarrow \mu_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

$$\|x_1 - \mu_1\| = 1.83$$

$$\|x_2 - \mu_1\| = 1.14$$

$$\|x_3 - \mu_1\| = 1.44$$

$$\|x_4 - \mu_1\| = 0.14$$

$$\|x_5 - \mu_1\| = 0.13$$

$$\|x_1 - \mu_2\| = 4$$

$$\|x_2 - \mu_2\| = 4$$

$$\|x_3 - \mu_2\| = 4.5$$

$$\|x_4 - \mu_2\| = 1$$

$$\|x_5 - \mu_2\| = 1$$

$$\rightarrow C_1 = \{x_1, x_2, x_3\}$$

$$C_2 = \{x_4, x_5\}$$

دسته‌ها تفسیر نمی‌کنند پس خروجی نهایی نیز همین دسته‌ها خواهد بود

سؤال 10

$$P(x) = \frac{\lambda^x e^{-\lambda}}{x!} \quad \sum_{j=1}^m a_{ij} = 1 \quad N_{ij} \sim P(a_{ij} \lambda_j)$$

likelihood

$$\rightarrow L(N_{ij})_{ij}(\lambda) = \prod_{i=1}^n \prod_{j=1}^m \frac{e^{-\lambda_j} \lambda_j^{a_{ij}}}{N_{ij}!} \rightarrow \left(\sum_{j=1}^m \lambda_j \right)^n$$

ب: نالاستق

$$\log L(N_{ij})_{ij}(\lambda) = \sum_{i=1}^n \sum_{j=1}^m (-\lambda_j a_{ij} + N_{ij} (\log(a_{ij} \lambda_j) - \log(N_{ij}!)))$$

$$\frac{\partial}{\partial \lambda_j} \rightarrow \sum_{i=1}^n -a_{ij} + \frac{1}{\lambda_j} E[N_{ij} | Y_i] = 0 \quad \rightarrow N_{ij} | Y_i \sim \text{Bin}(Y_i, \frac{a_{ij} \lambda_j}{\sum_{k=1}^m a_{ik} \lambda_k})$$

$$\Rightarrow \sum_{i=1}^n -a_{ij} + \frac{1}{\lambda_j} \frac{Y_i a_{ij} \lambda_j^{0.0}}{\sum_{k=1}^m a_{ik} \lambda_k^{0.0}} = 0 \Rightarrow \lambda_j^* = \frac{\lambda_j^{0.0}}{\sum_{i=1}^n a_{ij}} \cdot \sum_{i=1}^n \frac{Y_i a_{ij}}{\sum_{k=1}^m a_{ik} \lambda_k^{0.0}}$$

سؤال 1

$$P(z) = N(z | 0, I) \quad P(x|z) = N(x | wz + \mu, \sigma^2 I) \quad P(x) = N(x | \mu, \sigma^2 I)$$

$$P(x) = \int P(x, z) dz = \int P(x|z) P(z) dz \quad \mu = wz + \mu + \epsilon \rightarrow \text{ناب}$$

$$E[x] = E[wz + \mu + \epsilon] = wE[z] + E[\mu] + E[\epsilon] = \mu$$

$$C = E[(x - \mu)(x - \mu)^T] = E[(wz + \epsilon)(wz + \epsilon)^T] = E[wz z^T w + wz \epsilon^T + \epsilon^T w^T \epsilon + \epsilon \epsilon^T]$$

$$= w E[z z^T] w^T + 0 + 0 + E[\epsilon \epsilon^T] = w w^T + \sigma^2 I$$

(Bishop chapter 2) (ب)

$$P(z|x) = N(z | \tilde{m}^{-1} w^T (x - \mu), \tilde{\sigma}^{-2} M)$$

$$C^{-1} = \sigma^2 I - \tilde{\sigma}^2 w \tilde{m}^{-1} w^T \rightarrow M = w^T w + \sigma^2 I$$

سؤال 3 (ب)

1-D: $V = a$ 2-D: $V = a^2$ 3-D: $V = a^3 \rightarrow n$ -D: $V = a^n$

hypercube: $V_a = a^n$
 hypersphere: $V_r = \frac{\pi^{\frac{n}{2}} r^n}{\Gamma(\frac{n}{2} + 1)}$

$$\frac{V_a}{V_r} = \Gamma(\frac{n}{2} + 1) \left(\frac{r}{\pi}\right)^{\frac{n}{2}}$$


$n=1 \Rightarrow \frac{V_a}{V_r} = \frac{1}{\sqrt{\pi}}$ $n=2 \Rightarrow \frac{V_a}{V_r} = \frac{r}{\pi}$

$n=3 \Rightarrow \frac{V_a}{V_r} = \frac{r^2}{\sqrt{\pi} \pi}$ $n \rightarrow \infty \Rightarrow \frac{V_a}{V_r} = \lim_{n \rightarrow \infty} \Gamma(\frac{n}{2} + 1) \left(\frac{r}{\pi}\right)^{\frac{n}{2}} = \infty$

(6)

با توجه به نمودار زیر میبینیم بیشترین تاثیر را چند مقدار ویژه اول دارند که اندازه آنها برابر است با :

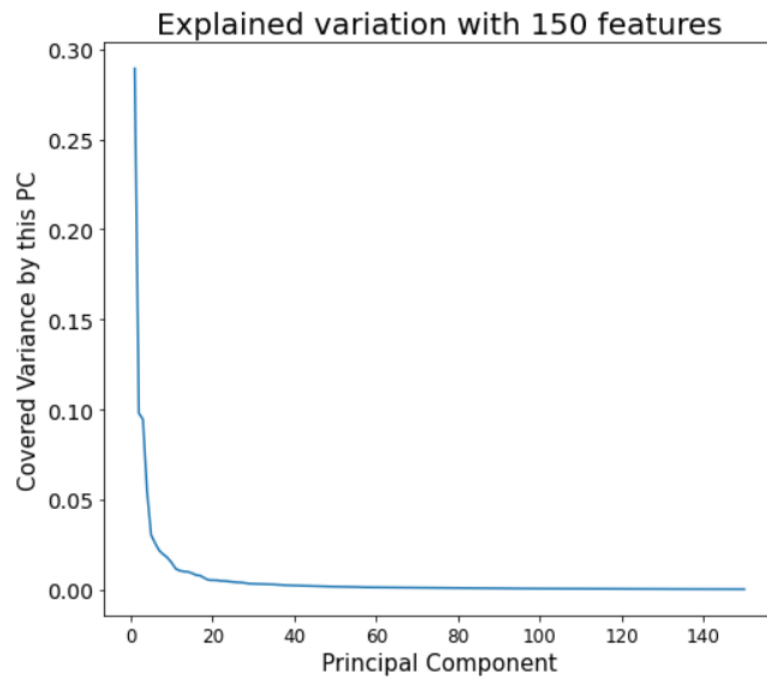
Explained variation per principal component for the first four PCs: [0.28923892 0.09806088 0.09456227 0.05485086]



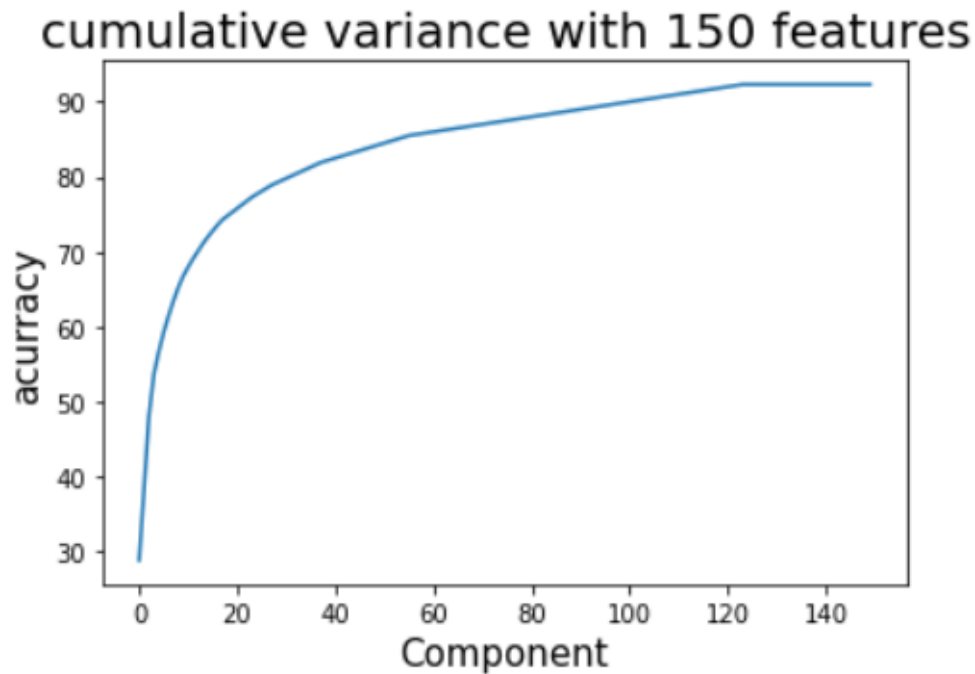
در شکل زیر نمودار واریانس تجمعی را میبینیم که نشان میدهد با تعداد فیچر های حدود 150 تا میتوانیم به دقت بالای 90 برسیم.

پس با کمک واریانس تجمعی میتوان تعداد کامپوننت مناسب را پیدا کرد

حال دوباره pca میزنیم و این بار فقط 150 تا فیچر را در نظر میگیریم.



واریانس تجمعی نیز نشان از دقت بالای 90 درصد می دهد.




Eigenface های اول فراوانی بیشتری دارند.

حال knn میزنیم


Knn با $k=1$ برای دادهای خالص

accuracy score on test data for : 0.40484814711618833




Knn با $k=2$ برای دادهای خالص

accuracy score on test data for : 0.3485650599052661




Knn با $k=1$ برای داده‌های کاهش بعد یافته

accuracy score on test data for : 0.4106993591529674



Knn با $k=2$ برای داده‌های کاهش بعد یافته

accuracy score on test data for : 0.3502368347729172



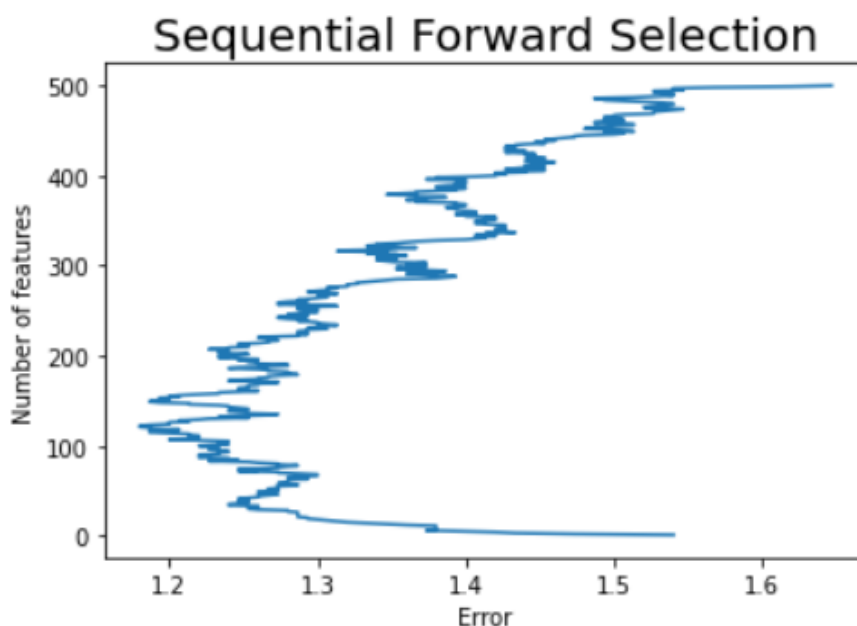
برای داده های کاهش بعد یافته با تعداد 1 همسایه بیشترین دقت و کمترین خطا را داریم.

```
for n in range(1,10):
    clf_knn = KNeighborsClassifier(n_neighbors=n)
    clf_knn.fit(new_x_train , y_train)
    pred = clf_knn.predict(new_x_test)
    score = accuracy_score(pred, y_test)
    print("accuracy score on test data with n={} for : {}".format(n ,score))
```

```
accuracy score on test data with n=1 for : 0.40484814711618833
accuracy score on test data with n=2 for : 0.3485650599052661
accuracy score on test data with n=3 for : 0.3390916689885762
accuracy score on test data with n=4 for : 0.3337977152410142
accuracy score on test data with n=5 for : 0.3365840066870995
accuracy score on test data with n=6 for : 0.32711061577040956
accuracy score on test data with n=7 for : 0.32683198662580104
accuracy score on test data with n=8 for : 0.32460295346893286
accuracy score on test data with n=9 for : 0.32850376149345223
```


Sequential Forward Selection

نمودار خطا بر حسب تعداد ویژگی به صورت زیر رسم می شود.
بر اساس این نمودار در آخر 120 ویژگی میتواند کمترین خطا را به ما بدهد.



Sequential Backward Elimination

نمودار دقت بر حسب تعداد ویژگی به صورت زیر رسم می شود.
بر اساس این نمودار در آخر 250 ویژگی میتواند کمترین خطا و بیشترین دقت را به ما بدهد.



از مزیت های backward میتوان به این اشاره کرد که سرعت و دقت این الگوریتم بیشتر است و خطای کمتری دارد.


در forward فرایند به گونه ایست که هر بار یک ویژگی اضافه می شود به صورتی که بیشترین دقت را در پیش بینی کردن ایجاد کند و فرایند انقدر ادامه پیدا میکند که ویژگی جدید در پیش بینی تاثیر مثبتی نداشته باشد.

در backward ابتدا همه ویژگی ها استفاده می شود و در هر مرحله ویژگی که تاثیر خاصی در پیش بینی نداشته باشد حذف می شود.

در کل backward بهتر کار میکند چون در forward در هر مرحله همه ی ویژگی های باقی مانده صدا می شوند و هزینه خیلی بیشتری دارد.

(8)

نمودار aic را برای داده ها رسم میکنیم.




بهترین تعداد component ها 110 تا است.


حال یک مدل با تعداد $110 = \text{component}$ فیت میکنیم و از آن 100 نمونه میگیریم و نمایش میدهیم.

1	8	8	6	0	0	5	2	2	9
9	9	7	4	1	1	1	2	3	3
3	3	3	2	8	1	0	2	2	1
6	7	7	0	0	0	7	2	2	4
4	4	4	9	4	5	5	2	2	4
1	9	8	9	8	1	2	4	4	2
2	5	7	2	4	4	0	0	3	7
7	7	9	5	5	8	8	7	5	1
2	2	2	3	0	0	0	4	2	3
2	2	0	7	7	4	4	6	9	9

همگرایی رخ داده است.

حال ابتدا کاهش بعد می‌دهیم و سپس aic ان را نمایش می‌دهیم.
برای component های 150 تا کمترین aic را داریم. با این تعداد یک مدل فیت می‌کنیم.






همگرایی رخ داده است.

نتایج در بخش ج بهتر شده است زیرا با pca تعداد ابعاد را کم کرده ایم در نتیجه کیفیت و نتایج بهتری داریم و دقت بالاتر می رود.


(9)

ابتدا دونرمال فیت میکنیم و کانتور های انها را رسم میکنیم.


countor for moon with label=0




countor for moon with label=1



مؤلفه 3



مؤلفه 8



مؤلفه 16

